Search models, datasets, users...

Datasets: Danielbrdz / **BarcenasNahuatl** Like 2

Tasks: Translation Modalities: Text Formats: json Size: 100K - 1M

Libraries: Datasets pandas Polars + 1 License: cc-by-sa-4.0

Dataset card | Data Studio | Files xet | Community 1

→ Copy to bucket NEW

</> Use this dataset

Downloads last month 20

Number of rows:
100,000

Total file size:
46.1 MB

Models trained or fine-tuned on `Danielbrdz/BarcenasNahuatl`

`Danielbrdz/BarcenasNahuatl-4b`
Text Generation • 4B • Updated Jan 7 • 17

Dataset Viewer Auto-converted to Parquet | API | Embed | Duplicate

Data Studio

Split (1)
train · 100k rows

Search this dataset

messages list · *lengths* 3 3	metadata dict
[{ "role": "system", "content": "Eres un experto en náhuatl…	{ "category": "vocabulario_directo", "subcategory":…
[{ "role": "system", "content": "Eres un experto en náhuatl…	{ "category": "vocabulario_directo", "subcategory": "sustantivos_familia",…
[{ "role": "system", "content": "Eres un experto en náhuatl…	{ "category": "vocabulario_directo", "subcategory": "sustantivos_cuerpo",…
[{ "role": "system", "content": "Eres un experto en náhuatl…	{ "category": "vocabulario_directo", "subcategory": "animales",…
[{ "role": "system", "content": "Eres un experto en náhuatl…	{ "category": "vocabulario_directo", "subcategory": "numeros",…
[{ "role": "system", "content":	{ "category": "vocabulario_directo",

Barcenas Náhuatl

Dataset de 100,000 ejemplos de traducción de español a náhuatl clásico.

El dataset está formado por:

Vocabulario directo: 27.3%

Gramática / Estructura: 23.6%

Conversaciones: 27.3%

Cultural / Filosófico: 21.8%

Todos los ejemplos fueron hechos de manera sintética por Kimi K2 Instruct 0905, usando un RAG especial de Náhuatl para mejorar su escritura en dicho idioma.

Adicional a esto, realicé un pequeño benchmark para evaluar el náhuatl de un LLM usando traducciones de náhuatl a español. Kimi K2 Instruct 0905, sin nada, sacó un 34.5, mientras que con el RAG sacó un 70.1, significando una mejora bastante considerable.

Muchas gracias a Nāhuatlahtolli por sus cursos libres y abiertos; sin su valiosa información hubiera sido imposible crear este dataset.

Un LLM y, en general, una IA es un excelente recurso para conservar un idioma completo de una cierta manera. No digo que mi proyecto lo haga, pero es un comienzo.

Aún con todo el trabajo realizado, no es suficiente para considerar que un LLM aprendió al 100% náhuatl. Faltan demasiadas cosas: más ejemplos, puede que alrededor un 30% de los datos no sean de la mejor calidad, un benchmark más confiable al estilo BBS3, etc.

Si algún día sale una segunda versión, habrá que pulir muchos aspectos del proyecto y tener mejores resultados en náhuatl.

Barcenas Nahuatl

Dataset of 100,000 translation examples from Spanish to classical Nahuatl.

The dataset is made up of:

Direct vocabulary: 27.3%

Grammar/Structure: 23.6%

Conversations: 27.3%

Cultural/Philosophical: 21.8%

All examples were made synthetically by Kimi K2 Instruct 0905, using a special Nahuatl RAG to improve his writing in that language.

In addition to this, I carried out a small benchmark to evaluate the Nahuatl of an LLM using translations from Nahuatl to Spanish. Kimi K2 Instruct 0905, without

anything, got a 34.5, while with the RAG he got a 70.1, meaning a fairly considerable improvement.

Many thanks to Nāhuatlahtolli for their free and open courses; Without their valuable information it would have been impossible to create this dataset.

An LLM and, in general, an IA is an excellent resource for preserving a complete language in a certain way. I'm not saying my project will do it, but it's a start.

Even with all the work done, it is not enough to consider that an LLM learned 100% Nahuatl. Too many things are missing: more examples, a more reliable BBS3-style benchmark, etc.

If a second version is released one day, many aspects of the project will have to be polished and have better results in Nahuatl.

Made with ❤ in Guadalupe, Nuevo Leon, Mexico □□

System theme

Company

TOS

Privacy

About

Careers

Website

Models

Datasets

Spaces

Pricing

Docs

